



DGTL

Анатомия современных трансформеров

Эволюция позиционных
эмбеддингов

Михаил Васильев

Райффайзенбанк



- Старший инженер по машинному обучению
- Raiffeisen Bank Russia
- Open-source enthusiast







- Информационный перегруз




- Информационный перегруз
- Срок годности знаний








Позиционные эмбединги



Позиционные эмбединги

Предложение 1

"Я не хочу работать, я хочу спать"




Позиционные эмбединги

Предложение 1


"Я не хочу работать, я хочу спать"

Предложение 2


"Я хочу работать, я не хочу спать"



- Относительность



- Относительность
- Экстраполяция



Absolute Positional Embeddings

Absolute Positional Embeddings

Формула

$$p_t^{(i)} = \begin{cases} \sin(\omega_k t), & \text{для } i = 2k \\ \cos(\omega_k t), & \text{для } i = 2k + 1 \end{cases}$$

где

$$\omega_k = \frac{1}{10000^{2k/d}}$$

Relative Positioning

t

$t + \phi$

Линейное преобразование

$$M \begin{bmatrix} \sin(\omega_k \cdot t) \\ \cos(\omega_k \cdot t) \end{bmatrix} = \begin{bmatrix} \sin(\omega_k \cdot (t + \phi)) \\ \cos(\omega_k \cdot (t + \phi)) \end{bmatrix}$$

t

$t + \phi$

Relative Positioning

Линейное преобразование

$$M \begin{bmatrix} \sin(\omega_k \cdot t) \\ \cos(\omega_k \cdot t) \end{bmatrix} = \begin{bmatrix} \sin(\omega_k \cdot (t + \phi)) \\ \cos(\omega_k \cdot (t + \phi)) \end{bmatrix}$$

t

$t + \phi$

Матрица

$$M = \begin{bmatrix} \cos(\omega_k \cdot \phi) & \sin(\omega_k \cdot \phi) \\ -\sin(\omega_k \cdot \phi) & \cos(\omega_k \cdot \phi) \end{bmatrix}$$

Плюсы

Плюсы

- Нет обучаемых параметров

Оригинальный трансформер

Плюсы

- Нет обучаемых параметров
- Экстраполяция

Оригинальный трансформер

Плюсы

- Нет обучаемых параметров
- Экстраполяция
- Относительные позиции

Оригинальный трансформер

Плюсы

- Нет обучаемых параметров
- Экстраполяция
- Относительные позиции

Минусы

Оригинальный трансформер

Плюсы

- Нет обучаемых параметров
- Экстраполяция
- Относительные позиции

Минусы

- Нет обучаемых параметров
- Плохая экстраполяция
- Плохие относительные позиции


```
nn.Embedding(max_len, hidden_size)
```

Плюсы

Плюсы

- Простота

Плюсы

- Простота
- Адаптивность

Плюсы

- Простота
- Адаптивность

Минусы

Плюсы

- Простота
- Адаптивность

Минусы

- Жёсткий лимит

Плюсы

- Простота
- Адаптивность

Минусы

- Жёсткий лимит
- Дополнительные параметры

Плюсы

- Простота
- Адаптивность

Минусы

- Жёсткий лимит
- Дополнительные параметры
- Нет явных относительных расстояний

Контент + позиция

$$q_i = (x_i + p_i)W^Q$$

$$k_j = (x_j + p_j)W^K$$

Original Transformer

Контент + позиция

$$q_i = (x_i + p_i)W^Q$$

$$k_j = (x_j + p_j)W^K$$

Скалярное произведение

$$A_{ij} = \frac{q_i k_j^\top}{\sqrt{d_k}}$$

Original Transformer

Контент + позиция

$$q_i = (x_i + p_i)W^Q$$

$$k_j = (x_j + p_j)W^K$$

Скалярное произведение

$$A_{ij} = \frac{q_i k_j^\top}{\sqrt{d_k}} \propto (x_i W^Q + p_i W^Q)(x_j W^K + p_j W^K)^\top$$

Original Transformer

Контент + позиция

$$q_i = (x_i + p_i)W^Q$$

$$k_j = (x_j + p_j)W^K$$

Скалярное произведение

$$A_{ij} = \frac{q_i k_j^\top}{\sqrt{d_k}} \propto (x_i W^Q + p_i W^Q)(x_j W^K + p_j W^K)^\top$$

$$A_{ij} \propto \underbrace{x_i W^Q (x_j W^K)^\top}_{1. \text{ Контент-Контент}} + \underbrace{x_i W^Q (p_j W^K)^\top}_{2. \text{ Контент-Позиция}} + \underbrace{p_i W^Q (x_j W^K)^\top}_{3. \text{ Позиция-Контент}} + \underbrace{p_i W^Q (p_j W^K)^\top}_{4. \text{ Позиция-Позиция}}$$

Относительное расстояние

$$R_{i-j}^{(2k)} = \sin \left(\frac{i-j}{10000^{2k/d_{\text{model}}}} \right)$$

$$R_{i-j}^{(2k+1)} = \cos \left(\frac{i-j}{10000^{2k/d_{\text{model}}}} \right)$$

Original Transformer vs Transformer-XL (Dai et al., 2019)

Четвертое слагаемое

$$p_i W^Q (p_j W^K)^\top$$

Original Transformer vs Transformer-XL (Dai et al., 2019)

Четвертое слагаемое

$$p_i W^Q (p_j W^K)^\top$$

Четвертое слагаемое

$$v W^Q (W^E R_{i-j})^\top$$

Original Transformer vs Transformer-XL (Dai et al., 2019)

Второе слагаемое

$$x_i W^Q (p_j W^K)^\top$$

Четвертое слагаемое

$$p_i W^Q (p_j W^K)^\top$$

Четвертое слагаемое

$$v W^Q (W^E R_{i-j})^\top$$

Original Transformer vs Transformer-XL (Dai et al., 2019)

Второе слагаемое

$$x_i W^Q (p_j W^K)^\top$$

Второе слагаемое

$$x_i W^Q (W^E R_{i-j})^\top$$

Четвертое слагаемое

$$p_i W^Q (p_j W^K)^\top$$

Четвертое слагаемое

$$v W^Q (W^E R_{i-j})^\top$$

Original Transformer vs Transformer-XL (Dai et al., 2019)

Второе слагаемое

$$x_i W^Q (p_j W^K)^\top$$

Третье слагаемое

$$p_i W^Q (x_j W^K)^\top$$

Четвертое слагаемое

$$p_i W^Q (p_j W^K)^\top$$

Второе слагаемое

$$x_i W^Q (W^E R_{i-j})^\top$$

Четвертое слагаемое

$$v W^Q (W^E R_{i-j})^\top$$

Original Transformer vs Transformer-XL (Dai et al., 2019)

Второе слагаемое

$$x_i W^Q (p_j W^K)^\top$$

Второе слагаемое

$$x_i W^Q (W^E R_{i-j})^\top$$

Третье слагаемое

$$p_i W^Q (x_j W^K)^\top$$

Третье слагаемое

$$u W^Q (x_j W^K)^\top$$

Четвертое слагаемое

$$p_i W^Q (p_j W^K)^\top$$

Четвертое слагаемое

$$v W^Q (W^E R_{i-j})^\top$$

Original Transformer vs Transformer-XL (Dai et al., 2019)

Первое слагаемое

$$x_i W^Q (x_j W^K)^\top$$

Второе слагаемое

$$x_i W^Q (p_j W^K)^\top$$

Третье слагаемое

$$p_i W^Q (x_j W^K)^\top$$

Четвертое слагаемое

$$p_i W^Q (p_j W^K)^\top$$

Второе слагаемое

$$x_i W^Q (W^E R_{i-j})^\top$$

Третье слагаемое

$$u W^Q (x_j W^K)^\top$$

Четвертое слагаемое

$$v W^Q (W^E R_{i-j})^\top$$

Original Transformer vs Transformer-XL (Dai et al., 2019)

Первое слагаемое

$$x_i W^Q (x_j W^K)^\top$$

Второе слагаемое

$$x_i W^Q (p_j W^K)^\top$$

Третье слагаемое

$$p_i W^Q (x_j W^K)^\top$$

Четвертое слагаемое

$$p_i W^Q (p_j W^K)^\top$$

Первое слагаемое

$$x_i W^Q (x_j W^K)^\top$$

Второе слагаемое

$$x_i W^Q (W^E R_{i-j})^\top$$

Третье слагаемое

$$u W^Q (x_j W^K)^\top$$

Четвертое слагаемое

$$v W^Q (W^E R_{i-j})^\top$$

Transformer-XL (Dai et al., 2019)

$$A_{ij}^{\text{XL}} \propto x_i W^Q (x_j W^K)^\top + x_i W^Q (W^E R_{i-j})^\top + u W^Q (x_j W^K)^\top + v W^Q (W^E R_{i-j})^\top$$

Плюсы

Плюсы

- Лучше экстраполяция

Плюсы

- Лучше экстраполяция
- Мало обучения

Плюсы

- Лучше экстраполяция
- Мало обучения

Минусы

Плюсы

- Лучше экстраполяция
- Мало обучения

Минусы

- Сложнее вычислительно

Плюсы

- Лучше экстраполяция
- Мало обучения

Минусы

- Сложнее вычислительно
- Фиксированные частоты

T5: Дешево и сердито

Формула внимания

$$A_{ij} = \frac{q_i k_j^\top}{\sqrt{d}} + b_{\text{bucket}(i-j)}$$

T5 Bucketing: Обучаемые скаляры

$i - j$	Бакет	Скаляры
0	0	b_0
1	1	b_1
2	2	b_2
$\vdots$	$\vdots$	$\vdots$
15	15	b_{15}

T5 Bucketing: Обучаемые скаляры

$i - j$	Бакет	Скаляры
0	0	b_0
1	1	b_1
2	2	b_2
$\vdots$	$\vdots$	$\vdots$
15	15	b_{15}
16-18	16	b_{16}

T5 Bucketing: Обучаемые скаляры

$i - j$	Бакет	Скаляры
0	0	b_0
1	1	b_1
2	2	b_2
$\vdots$	$\vdots$	$\vdots$
15	15	b_{15}
16-18	16	b_{16}
19-20	17	b_{17}

T5 Bucketing: Обучаемые скаляры

$i - j$	Бакет	Скаляры
0	0	b_0
1	1	b_1
2	2	b_2
$\vdots$	$\vdots$	$\vdots$
15	15	b_{15}
16-18	16	b_{16}
19-20	17	b_{17}
$\vdots$	$\vdots$	$\vdots$
87-98	29	b_{29}
99-112	30	b_{30}
113+	31	b_{31}

Плюсы

Плюсы

- Относительные позиции

Плюсы

- Относительные позиции
- Минимальные накладные расходы

Плюсы

- Относительные позиции
- Минимальные накладные расходы
- Экстраполяция

Плюсы

- Относительные позиции
- Минимальные накладные расходы
- Экстраполяция
- Простота

Плюсы

- Относительные позиции
- Минимальные накладные расходы
- Экстраполяция
- Простота

Минусы

Плюсы

- Относительные позиции
- Минимальные накладные расходы
- Экстраполяция
- Простота

Минусы

- Потеря детализации

Плюсы

- Относительные позиции
- Минимальные накладные расходы
- Экстраполяция
- Простота

Минусы

- Потеря детализации
- Фиксированная схема бакетов


Плюсы

- Относительные позиции
- Минимальные накладные расходы
- Экстраполяция
- Простота

Минусы


- Потеря детализации
- Фиксированная схема бакетов
- Обучаемые параметры

RoPE: позиция как угол поворота




$$\mathbf{q}_i \cdot \mathbf{k}_j = \|\mathbf{q}_i\| \|\mathbf{k}_j\| \cos(\beta - \alpha)$$

RoPE: позиция как угол поворота




$$\mathbf{q}_i \cdot \mathbf{k}_j = \|\mathbf{q}_i\| \|\mathbf{k}_j\| \cos(\beta - \alpha)$$

RoPE: позиция как угол поворота



$$\mathbf{q}_i \cdot \mathbf{k}_j = \|\mathbf{q}_i\| \|\mathbf{k}_j\| \cos(\beta - \alpha)$$


RoPE: позиция как угол поворота



$$\mathbf{q}_i \cdot \mathbf{k}_j = \|\mathbf{q}_i\| \|\mathbf{k}_j\| \cos(\beta - \alpha)$$

$$\mathbf{q}'_i \cdot \mathbf{k}'_j = \|\mathbf{q}_i\| \|\mathbf{k}_j\| \cos((\beta + n\theta) - (\alpha + m\theta))$$

RoPE: позиция как угол поворота



$$\mathbf{q}_i \cdot \mathbf{k}_j = \|\mathbf{q}_i\| \|\mathbf{k}_j\| \cos(\beta - \alpha)$$

$$\mathbf{q}'_i \cdot \mathbf{k}'_j = \|\mathbf{q}_i\| \|\mathbf{k}_j\| \cos((\beta + n\theta) - (\alpha + m\theta))$$

$$\mathbf{q}'_i \cdot \mathbf{k}'_j = \|\mathbf{q}_i\| \|\mathbf{k}_j\| \cos((\beta - \alpha) + (n - m)\theta)$$

А как вращать-то?

$$\mathbf{q} = \begin{bmatrix} q_0 \\ q_1 \\ q_2 \\ q_3 \\ q_4 \\ q_5 \\ \vdots \\ q_{127} \end{bmatrix} \quad \mathbf{R}_{\text{naive}}^{(q)} = \begin{bmatrix} r_{0,0} & r_{0,1} & r_{0,2} & r_{0,3} & r_{0,4} & r_{0,5} & \cdots & r_{0,127} \\ r_{1,0} & r_{1,1} & r_{1,2} & r_{1,3} & r_{1,4} & r_{1,5} & \cdots & r_{1,127} \\ r_{2,0} & r_{2,1} & r_{2,2} & r_{2,3} & r_{2,4} & r_{2,5} & \cdots & r_{2,127} \\ r_{3,0} & r_{3,1} & r_{3,2} & r_{3,3} & r_{3,4} & r_{3,5} & \cdots & r_{3,127} \\ r_{4,0} & r_{4,1} & r_{4,2} & r_{4,3} & r_{4,4} & r_{4,5} & \cdots & r_{4,127} \\ r_{5,0} & r_{5,1} & r_{5,2} & r_{5,3} & r_{5,4} & r_{5,5} & \cdots & r_{5,127} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ r_{127,0} & r_{127,1} & r_{127,2} & r_{127,3} & r_{127,4} & r_{127,5} & \cdots & r_{127,127} \end{bmatrix}$$

Вращение только в плоскости (q_0, q_1)

Вращение только в плоскости (q_0, q_1)

$$\mathbf{q} = \begin{bmatrix} q_0 \\ q_1 \\ q_2 \\ q_3 \\ q_4 \\ q_5 \\ \vdots \\ q_{127} \end{bmatrix} \quad \mathbf{R}^{(q)} = \begin{bmatrix} r_{0,0} & r_{0,1} & 0 & 0 & 0 & 0 & \dots & 0 \\ r_{1,0} & r_{1,1} & 0 & 0 & 0 & 0 & \dots & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & \dots & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & \dots & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & \dots & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & 0 & 0 & \dots & 0 \end{bmatrix}$$

Вращение только в плоскости (q_2, q_3)

$$\mathbf{q} = \begin{bmatrix} q_0 \\ q_1 \\ q_2 \\ q_3 \\ q_4 \\ q_5 \\ \vdots \\ q_{127} \end{bmatrix} \quad \mathbf{R}^{(q)} = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 & \dots & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & \dots & 0 \\ 0 & 0 & r_{2,2} & r_{2,3} & 0 & 0 & \dots & 0 \\ 0 & 0 & r_{3,2} & r_{3,3} & 0 & 0 & \dots & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & \dots & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & 0 & 0 & \dots & 0 \end{bmatrix}$$

Блочно-диагональная матрица

$$\mathbf{q} = \begin{bmatrix} q_0 \\ q_1 \\ \hline q_2 \\ q_3 \\ \hline q_4 \\ q_5 \\ \hline \vdots \\ q_{127} \end{bmatrix} \quad \mathbf{R}^{(q)} = \begin{bmatrix} r_{0,0} & r_{0,1} & 0 & 0 & 0 & 0 & \dots & 0 \\ r_{1,0} & r_{1,1} & 0 & 0 & 0 & 0 & \dots & 0 \\ 0 & 0 & r_{2,2} & r_{2,3} & 0 & 0 & \dots & 0 \\ 0 & 0 & r_{3,2} & r_{3,3} & 0 & 0 & \dots & 0 \\ 0 & 0 & 0 & 0 & r_{4,4} & r_{4,5} & \dots & 0 \\ 0 & 0 & 0 & 0 & r_{5,4} & r_{5,5} & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & 0 & 0 & \dots & r_{127,127} \end{bmatrix}$$

Вращение пар

$$(q_0, q_1) \rightarrow m \cdot \theta_0$$

$$(q_2, q_3) \rightarrow m \cdot \theta_1$$

$$(q_4, q_5) \rightarrow m \cdot \theta_2$$

$$(q_6, q_7) \rightarrow m \cdot \theta_3$$

...

$$(q_{20}, q_{21}) \rightarrow m \cdot \theta_{10}$$

...

$$(q_{40}, q_{41}) \rightarrow m \cdot \theta_{20}$$

...

$$(q_{126}, q_{127}) \rightarrow m \cdot \theta_{63}$$

Вращение пар

$$(q_0, q_1) \rightarrow m \cdot \theta_0$$

$$(q_2, q_3) \rightarrow m \cdot \theta_1$$

$$(q_4, q_5) \rightarrow m \cdot \theta_2$$

$$(q_6, q_7) \rightarrow m \cdot \theta_3$$

...

$$(q_{20}, q_{21}) \rightarrow m \cdot \theta_{10}$$

...

$$(q_{40}, q_{41}) \rightarrow m \cdot \theta_{20}$$

...

$$(q_{126}, q_{127}) \rightarrow m \cdot \theta_{63}$$

Частоты

$$\theta_i = 10000^{-2i/128}$$

Вращение пар

$$(q_0, q_1) \rightarrow m \cdot \theta_0$$

$$(q_2, q_3) \rightarrow m \cdot \theta_1$$

$$(q_4, q_5) \rightarrow m \cdot \theta_2$$

$$(q_6, q_7) \rightarrow m \cdot \theta_3$$

...

$$(q_{20}, q_{21}) \rightarrow m \cdot \theta_{10}$$

...

$$(q_{40}, q_{41}) \rightarrow m \cdot \theta_{20}$$

...

$$(q_{126}, q_{127}) \rightarrow m \cdot \theta_{63}$$

Частоты

$$\theta_i = 10000^{-2i/128}$$

$$10000^0 = 1,0000$$

$$10000^{-2/128} = 0,8660$$

$$10000^{-4/128} = 0,8286$$

$$10000^{-6/128} = 0,7500$$

...

$$10000^{-20/128} = 0,2371$$

...

$$10000^{-40/128} = 0,0562$$

...

$$10000^{-126/128} = 0,0001$$

Матрица поворота

$$\mathbf{R}(\phi) = \begin{bmatrix} \cos \phi & -\sin \phi \\ \sin \phi & \cos \phi \end{bmatrix}$$

Матрица поворота

$$\mathbf{R}(\phi) = \begin{bmatrix} \cos \phi & -\sin \phi \\ \sin \phi & \cos \phi \end{bmatrix}$$

$$\theta_i = 10000^{-2i/128}$$

Эффективные повороты

Матрица поворота

$$\mathbf{R}(\phi) = \begin{bmatrix} \cos \phi & -\sin \phi \\ \sin \phi & \cos \phi \end{bmatrix}$$

$$\theta_i = 10000^{-2i/128}$$

$$c_i = \cos(m\theta_i)$$

$$s_i = \sin(m\theta_i)$$

Эффективные повороты

Матрица поворота

$$\mathbf{R}(\phi) = \begin{bmatrix} \cos \phi & -\sin \phi \\ \sin \phi & \cos \phi \end{bmatrix}$$

$$\theta_i = 10000^{-2i/128}$$

$$c_i = \cos(m\theta_i)$$
$$s_i = \sin(m\theta_i)$$

$$\begin{bmatrix} q'_{2i} \\ q'_{2i+1} \end{bmatrix} = \begin{bmatrix} c_i & -s_i \\ s_i & c_i \end{bmatrix} \begin{bmatrix} q_{2i} \\ q_{2i+1} \end{bmatrix}$$

Плюсы

Плюсы

- Быстрый

Плюсы

- Быстрый
- Нет дополнительных весов

Плюсы

- Быстрый
- Нет дополнительных весов
- Экстраполируется

Плюсы

- Быстрый
- Нет дополнительных весов
- Экстраполируется

Минусы

Плюсы

- Быстрый
- Нет дополнительных весов
- Экстраполируется

Минусы

- Фиксированные частоты

Плюсы

- Быстрый
- Нет дополнительных весов
- Экстраполируется

Минусы

- Фиксированные частоты
- Очень длинные последовательности

Плюсы

- Быстрый
- Нет дополнительных весов
- Экстраполируется

Минусы

- Фиксированные частоты
- Очень длинные последовательности
- Сложнее реализация

Заключение

- От абсолютного к относительному

Заключение

- От абсолютного к относительному
- От аддитивного к геометрическому

- **Transformer**
<https://arxiv.org/abs/1706.03762>
- **BERT**
<https://arxiv.org/abs/1810.04805>
- **Transformer-XL**
<https://arxiv.org/abs/1901.02860>
- **T5**
<https://arxiv.org/abs/1910.10683>
- **RoPE**
<https://arxiv.org/abs/2104.09864>



DGTL

Готов ответить
на ваши вопросы

