

# Кластеризация

разбираемся, почему она работает и зачем нужна

Михаил Васильев

17 апреля 2026 г.

# Обо мне


- Старший инженер по машинному обучению
- Raiffeisen Bank Russia, HRTech
- NLP, CV, AD, ML
- open-source enthusiast
- Объясняю простое простыми словами





## Вопрос

Нравится ли вам работать с большими таблицами?




# Кластеризация



# Кластеризация



# Кластеризация



# Кластеризация

# Python

```
from sklearn.cluster import KMeans
import numpy as np

X = np.array([[1, 2], [1, 4], [1, 0],
              [10, 2], [10, 4], [10, 0]])

kmeans = KMeans(n_clusters=2).fit(X)

print(kmeans.labels_)
# array([1, 1, 1, 0, 0, 0], dtype=int32)
```

# Евклидово расстояние...

# Евклидово расстояние...

на плоскости

$$d(A, B) = \sqrt{(x_B - x_A)^2 + (y_B - y_A)^2}$$

# Евклидово расстояние...

в трёхмерном пространстве

$$d(A, B) = \sqrt{(x_B - x_A)^2 + (y_B - y_A)^2 + (z_B - z_A)^2}$$

# Евклидово расстояние...

в  $n$ -мерном пространстве! Кайф!

$$d(A, B) = \sqrt{\sum_{i=1}^n (a_i - b_i)^2}$$

# Евклидово расстояние...


## Min-Max Scaling

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$


в n-мерном пространстве! Кайф!

$$d(A, B) = \sqrt{\sum_{i=1}^n (a_i - b_i)^2}$$


# k-Means




# k-Means




# k-Means




# k-Means




# k-Means




# k-Means




# k-Means




# k-Means




# k-Means




# k-Means




# k-Means



# k-Means



# k-Means



# k-Means

Плюсы

# k-Means

## Плюсы

- Простой и быстрый

# k-Means

## Плюсы

- Простой и быстрый
- Легко интерпретировать

# k-Means

## Плюсы

- Простой и быстрый
- Легко интерпретировать

## Минусы

# k-Means

## Плюсы

- Простой и быстрый
- Легко интерпретировать

## Минусы

- Нужно выбрать  $k$

# k-Means

## Плюсы

- Простой и быстрый
- Легко интерпретировать

## Минусы

- Нужно выбрать  $k$
- Чувствителен к начальному положению центроидов

# k-Means

## Плюсы

- Простой и быстрый
- Легко интерпретировать

## Минусы

- Нужно выбрать  $k$
- Чувствителен к начальному положению центроидов
- Чувствителен к выбросам

# k-Means


## Плюсы

- Простой и быстрый
- Легко интерпретировать


## Минусы

- Нужно выбрать  $k$
- Чувствителен к начальному положению центроидов
- Чувствителен к выбросам
- Плохо работает с плотностью и формой


# Silhouette Score



# Silhouette Score



# Silhouette Score



# Silhouette Score

Свой кластер

$$a(i) = \frac{1}{|C_i| - 1} \sum_{j \in C_i, j \neq i} d(i, j)$$

# Silhouette Score

Свой кластер

$$a(i) = \frac{1}{|C_i| - 1} \sum_{j \in C_i, j \neq i} d(i, j)$$

Ближайший чужой кластер

$$b(i) = \min_{k \neq i} \left( \frac{1}{|C_k|} \sum_{j \in C_k} d(i, j) \right)$$

# Silhouette Score

Одна точка

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

# Silhouette Score


Одна точка

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$


Общий скор

$$S = \frac{1}{n} \sum_{i=1}^n s(i)$$


$k = 2$ , Silhouette Score = 0.431




$k = 3$ , Silhouette Score = 0.580




$k = 4$ , Silhouette Score = 0.466




$k = 5$ , Silhouette Score = 0.402




$k = 6$ , Silhouette Score = 0.334




# DBSCAN




# DBSCAN




# DBSCAN




# DBSCAN




# DBSCAN




# DBSCAN




# DBSCAN



# DBSCAN



# DBSCAN



## Плюсы

## Плюсы

- Любое число кластеров

## Плюсы

- Любое число кластеров
- Кластера произвольной формы

## Плюсы

- Любое число кластеров
- Кластера произвольной формы
- Устойчив к шуму

## Плюсы

- Любое число кластеров
- Кластера произвольной формы
- Устойчив к шуму

## Минусы

## Плюсы

- Любое число кластеров
- Кластера произвольной формы
- Устойчив к шуму

## Минусы

- Нужно выбрать  $\epsilon$  и  $minPts$

## Плюсы

- Любое число кластеров
- Кластера произвольной формы
- Устойчив к шуму

## Минусы

- Нужно выбрать  $\epsilon$  и  $minPts$
- Медленный


## Плюсы

- Любое число кластеров
- Кластера произвольной формы
- Устойчив к шуму


## Минусы

- Нужно выбрать  $\epsilon$  и  $minPts$
- Медленный
- Сложно интерпретировать


# Метод локтя




# Метод локтя





# Метод локтя




# Метод локтя











# Иерархия














# Иерархия





# Иерархия





# Иерархия





# Иерархия





# Иерархия





# Иерархия





# Иерархия





# Иерархия





# Иерархия





# Иерархия





# Иерархия





# Иерархия





# Иерархия





# Иерархия



# Иерархия



# Иерархия



# Иерархия

Плюсы

# Иерархия

## Плюсы

- Не требует ничего

# Иерархия

## Плюсы

- Не требует ничего
- Наглядное дерево

# Иерархия

## Плюсы

- Не требует ничего
- Наглядное дерево
- Удобно для анализа

# Иерархия

## Плюсы

- Не требует ничего
- Наглядное дерево
- Удобно для анализа

## Минусы

# Иерархия

## Плюсы

- Не требует ничего
- Наглядное дерево
- Удобно для анализа

## Минусы

- $O(n^2)$

# Иерархия

## Плюсы

- Не требует ничего
- Наглядное дерево
- Удобно для анализа

## Минусы

- $O(n^2)$
- Неустойчиво к изменению данных

# Иерархия

## Плюсы

- Не требует ничего
- Наглядное дерево
- Удобно для анализа

## Минусы

- $O(n^2)$
- Неустойчиво к изменению данных
- Требует анализа

## Что учитываем

## Что учитываем

- Интерпретируемость

## Что учитываем

- Интерпретируемость
- Есть ли шум

## Что учитываем

- Интерпретируемость
- Есть ли шум
- Ожидаемая форма

## Что учитываем

- Интерпретируемость
- Есть ли шум
- Ожидаемая форма
- Число кластеров

## Что учитываем

- Интерпретируемость
- Есть ли шум
- Ожидаемая форма
- Число кластеров
- Ограничение по скорости

# Вопросики?

